

## 1. Aproximación por mínimos cuadrados discreta y continua

Principio del mínimo

$A \in \mathbb{R}^{N \times N}$  es una matriz simétrica y definida positiva.  
 $b \in \mathbb{R}^N$  y  $f: \mathbb{R}^N \rightarrow \mathbb{R}$  es la forma cuadrática definida en cada  $x \in \mathbb{R}^N$  como

$$f(x) = \frac{1}{2} x^T A x - b^T x$$

$f$  alcanza su mínimo en el vector solución de  $Ax = b$   
 cuyo valor mínimo es  $-\frac{1}{2} b^T A^{-1} b$

1)\* Demostración

Primero veamos que  $A$  es regular. Supongamos que  $Ax = 0$ .  
 Entonces,  $x^T A x = 0$  ya que cualquier vector por el vector nulo es 0. Como  $A$  es definida positiva,  $x = 0$ , lo cual quiere decir que el sistema dado por  $Ax = 0$  es un SCD y, por lo tanto,  $A$  es regular. Ya podemos probar que en  $x = A^{-1}b$  se alcanza el mínimo:

$$f(y) - f(x) = \frac{1}{2} y^T A y - b^T y - \frac{1}{2} x^T A x + b^T x =$$

Usamos que  $b = Ax$   
 $\downarrow$   
 Agrupamos los términos  $x^T A x$

$$= \frac{1}{2} y^T A y - x^T A y - \frac{1}{2} x^T A x + x^T A x =$$

$$= \frac{1}{2} y^T A y + \frac{1}{2} x^T A x - x^T A y = \frac{1}{2} (y^T A y + x^T A x - 2x^T A y)$$

$$= \frac{1}{2} (y - x)^T \cdot A \cdot (y - x) \Rightarrow$$

Como  $A$  es definida positiva,  $f(y) - f(x) \geq 0$ , lo cual demuestra que en  $x = A^{-1}b$  se alcanza el mínimo.

Aplicamos simetría de  $A$   
 $(a-b)^2 = a^2 + b^2 - 2ab$

2)\* Demostración

$A \in \mathbb{R}^{N \times N}$ ,  $\text{rango}(A) = N \Leftrightarrow$  columnas de  $A$  linealmente independientes

$\Downarrow$   
 $\hat{A}$  simétrica y definida positiva?

1) Claramente  $ATA$  es simétrica pues  $(ATA)^T = A^T(A^T)^T = A^T A$



2') Para ver que es definida positiva, sea  $x \in \mathbb{R}^N$ :  
 $x \neq 0$

$$x^T (A^T A) x > 0? \Rightarrow x^T (A^T A) x = (Ax)^T Ax = \|Ax\|_2^2 \geq 0$$

$$\text{De hecho } \|Ax\|_2^2 = 0 \Leftrightarrow \|Ax\|_2 = 0 \Leftrightarrow Ax = 0$$

$$0 = Ax = \underbrace{[a_1 \dots a_N]}_{\text{columnas de } A} x = x_1 a_1 + \dots + x_N a_N = 0$$

Como las columnas de  $A$  son L.I., necesariamente  $x_1 = \dots = x_N = 0$  y hemos demostrado que  $A^T A$  es definida positiva.

### Aproximación por mínimos cuadrados discreta

Sea  $S$  un subespacio vectorial de  $\mathbb{R}^n$  de dimensión  $N$ :

$$S = \mathcal{L} \left\{ \begin{bmatrix} a_{11} \\ \vdots \\ a_{n1} \end{bmatrix}, \dots, \begin{bmatrix} a_{1N} \\ \vdots \\ a_{nN} \end{bmatrix} \right\} \text{ base de } S$$

A matriz con columnas los vectores de la base de  $S$ .

$\text{rango}(A) = N$  porque son L.I.  $S = \{Ax : x \in \mathbb{R}^N\}$   
(en paramétricas)

Como los vectores de  $S$  son de la forma  $Ax$ ,  $b \in S$  si  $Ax = b$  es un SCD y  $b \notin S$  si  $Ax = b$  es un sistema incompatible o SCI

Vamos a buscar el vector de  $S$  más próximo a uno dado  $b \in \mathbb{R}^n$ , es decir, hemos de hallar  $x \in \mathbb{R}^N$  tal que  $\forall y \in \mathbb{R}^N$  se cumpla  $\|Ay - b\|_2^2 \geq \|Ax - b\|_2^2$ . Tomemos  $f(x) = \|Ax - b\|_2^2$  y veamos cuándo es mínima:

### 3)\* Demostración

$$\begin{aligned} f(x) &= \|Ax - b\|_2^2 = (Ax - b)^T (Ax - b) = x^T A^T A x - 2b^T A x + b^T b = \\ &= 2 \left( \frac{1}{2} x^T A^T A x - (A^T b)^T x \right) + b^T b \end{aligned}$$

Esta es justo la función que ha aparecido en el principio del mínimo, y podemos aplicar dicho principio por la  $A^T A$  simétrica y definida positiva.  $f$  es mínima para  $A^T A x = A^T b$ .  
**¡IMPORTANTE!**  $\Rightarrow$  El vector de  $S$  más cercano a  $b$  será  $A(A^T A)^{-1} A^T b$



Otra forma de plantear el problema es el siguiente:

$$A^T A x = A^T b$$



$$A^T b - A^T A x = 0 \Leftrightarrow A^T (b - A x) = 0 \Rightarrow \text{Esto equivale a imponer que el producto escalar de cada columna de } A \text{ y el vector } b - A x \text{ sea } 0.$$

$$\forall j \in \{1, \dots, N\} \Rightarrow \left\langle \begin{bmatrix} a_{1j} \\ \vdots \\ a_{nj} \end{bmatrix}, b - A x \right\rangle = 0$$

Esto significa que  $b - A x$  es  $\perp$  a todos los vectores de la base de  $S$  ( $b - A x \in S^\perp$ ). De ahí que se llame a  $A x$  proyección ortogonal de  $b$  sobre  $S$ .

Como  $A x = \sum_{i=1}^N x_i \begin{bmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{bmatrix}$ , podemos reescribir el producto escalar como:

y esto se resume también en resolver un sistema.

$$\forall j \in \{1, \dots, N\} \Rightarrow \left\langle \begin{bmatrix} a_{1j} \\ \vdots \\ a_{nj} \end{bmatrix}, b - \sum_{i=1}^N x_i \begin{bmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{bmatrix} \right\rangle = 0$$

Resumimos todo lo visto en el siguiente teorema:

### Teorema de la mejor aproximación ( $\mathbb{R}^n$ )

Sea  $A \in \mathbb{R}^{n \times N}$  con  $\text{rango}(A) = N$  y sea  $S$  el subespacio:

$$S := \{A x : x \in \mathbb{R}^N\}$$

y sea  $b \in \mathbb{R}^n$ . Entonces existe un único vector  $x \in \mathbb{R}^N$  tal que

$$\|A x - b\|_2 = \min \{ \|A y - b\|_2 : y \in \mathbb{R}^N \}$$

siendo  $A x$  la mejor aproximación de  $b$  en  $S$  y proyección ortogonal de  $b$  sobre  $S$  simultáneamente, que viene caracterizada por:

$$A^T A x = A^T b \quad (\text{Ecuaciones normales})$$

$$\forall j \in \{1, \dots, N\} \Rightarrow \left\langle \begin{bmatrix} a_{1j} \\ \vdots \\ a_{nj} \end{bmatrix}, b - \sum_{i=1}^N x_i \begin{bmatrix} a_{1i} \\ \vdots \\ a_{ni} \end{bmatrix} \right\rangle = 0$$

### Aplicaciones

#### Ajuste mínimos cuadrados

Dados los datos  $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n) \in \mathbb{R}^2$ , buscamos una función que pase lo más cerca posible de todos los puntos a la vez.





Queremos minimizar la suma de los errores al cuadrado:

$$\sum_{i=0}^n (ax_i + b - y_i)^2$$

$$\left\| a \begin{bmatrix} x_0 \\ \vdots \\ x_n \end{bmatrix} + b \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} - \begin{bmatrix} y_0 \\ \vdots \\ y_n \end{bmatrix} \right\|_2^2$$

Si consideramos  $S := \mathcal{L} \left\{ \begin{bmatrix} x_0 \\ \vdots \\ x_n \end{bmatrix}, \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right\}$  con  $\dim(S) = 2$ , de

la anterior expresión y comparándola con la de la mejor aproximación deducimos que el ajuste de mínimos cuadrados equivale a  $P_S(y) = a \cdot x + b \cdot 1$

Si fuese con una parábola de la forma  $f(x) = ax^2 + bx + c$ , mismo razonamiento:

$$\text{Minimizar } \sum_{i=0}^n (ax_i^2 + bx_i + c - y_i)^2$$

$$\text{Minimizar } \left\| a \begin{bmatrix} x_0^2 \\ \vdots \\ x_n^2 \end{bmatrix} + b \begin{bmatrix} x_0 \\ \vdots \\ x_n \end{bmatrix} + c \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} - \begin{bmatrix} y_0 \\ \vdots \\ y_n \end{bmatrix} \right\|_2^2$$

Consideramos  $S := \mathcal{L} \left\{ \begin{bmatrix} x_0^2 \\ \vdots \\ x_n^2 \end{bmatrix}, \begin{bmatrix} x_0 \\ \vdots \\ x_n \end{bmatrix}, \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right\}$  con  $\dim(S) = 3$  y

la solución será  $P_S(y) = a \cdot x^2 + b \cdot x + c \cdot 1$

### Caso continuo

**Definición.** Dado un esp. vect.  $E$ , la aplicación  $\langle \cdot, \cdot \rangle : E \times E \rightarrow \mathbb{R}$  es un producto escalar en  $E$  siempre que

- $\langle x, y \rangle = \langle y, x \rangle$  (Simetría)
  - $\langle x + y, z \rangle = \langle x, z \rangle + \langle y, z \rangle$  (Linealidad en cada componente)
  - $\langle \lambda x, y \rangle = \lambda \langle x, y \rangle \quad \forall x, y, z \in E \quad \lambda \in \mathbb{R}$
  - $\langle x, x \rangle \geq 0$  con " $=$ "  $\Leftrightarrow x = 0$
- y entonces  $E$  pasa a ser espacio euclídeo con producto escalar  $\langle \cdot, \cdot \rangle$

## Ejemplos productos escalares

$$\begin{aligned} \bullet E = \mathbb{R}^N & \quad \bullet E = C([a, b]) \\ x, y \in \mathbb{R}^N \Rightarrow \langle x, y \rangle &:= \sum_{i=1}^N x_i y_i \quad f, g \in C([a, b]) \Rightarrow \langle f, g \rangle := \int_a^b f(x) g(x) dx \end{aligned}$$

Consecuencia inmediata de la definición de producto escalar:

$$\bullet \langle x, 0 \rangle = 0 \quad \bullet \left\langle \sum_{i=1}^N \lambda_i x_i, \sum_{j=1}^M \mu_j y_j \right\rangle = \sum_{i=1}^N \sum_{j=1}^M \lambda_i \mu_j \langle x_i, y_j \rangle$$

Siendo los  $\lambda_i, \mu_j \in E$  y  $x_i, y_j \in E$

Definición de norma  $\Rightarrow x \in E \Rightarrow \|x\| := \sqrt{\langle x, x \rangle}$

## Ejemplos normas

$$\begin{aligned} \bullet E = \mathbb{R}^N & \quad \bullet E = C([a, b]) \\ x \in \mathbb{R}^N \Rightarrow \|x\| &= \sqrt{\sum_{i=1}^N x_i^2} \quad f \in C([a, b]) \Rightarrow \|f\| = \sqrt{\int_a^b f(x)^2 dx} \end{aligned}$$

## Aproximación en un espacio euclídeo arbitrario

Sea  $(E, \langle \cdot, \cdot \rangle)$  espacio euclídeo,  $v \in E$ ,  $S$  subespacio finito dimensional vectorial de  $E$  y  $\{a_1, \dots, a_n\}$  base de  $S$

¿Existe  $u \in S$  más próximo a  $v$ ?

¿Existe  $u \in S : w \in S \Rightarrow \|u - v\| \leq \|w - v\|$ ?

↙ Elevamos al cuadrado

$$\|u - v\|^2 \leq \|w - v\|^2$$

$$\langle u - v, u - v \rangle \leq \langle w - v, w - v \rangle$$

$$\left. \begin{matrix} x \in \mathbb{R}^N \\ y \in \mathbb{R}^N \end{matrix} \right\} \Rightarrow \left\langle \sum_{i=1}^N x_i a_i - v, \sum_{j=1}^N x_j a_j - v \right\rangle \leq \left\langle \sum_{i=1}^N y_i a_i - v, \sum_{j=1}^N y_j a_j - v \right\rangle$$

⇔ ¿Existe  $x \in \mathbb{R}^N$ ?

Desarrollamos los productos escalares

$$\sum_{i=1}^N \sum_{j=1}^N x_i x_j \langle a_i, a_j \rangle + v^2 - 2 \sum_{i=1}^N x_i \langle a_i, v \rangle \leq \sum_{i=1}^N \sum_{j=1}^N y_i y_j \langle a_i, a_j \rangle + v^2 - 2 \sum_{i=1}^N y_i \langle a_i, v \rangle$$

$$\sum_{i=1}^N \sum_{j=1}^N x_i x_j \langle a_i, a_j \rangle - 2 \sum_{i=1}^N x_i \langle a_i, v \rangle \leq \sum_{i=1}^N \sum_{j=1}^N y_i y_j \langle a_i, a_j \rangle - 2 \sum_{i=1}^N y_i \langle a_i, v \rangle \quad (*)$$

Consideremos ahora la matriz  $A$  y el vector  $b$ :



$$A := \begin{bmatrix} \langle a_i, a_j \rangle \end{bmatrix} \quad b := \begin{bmatrix} \langle a_1, v \rangle \\ \vdots \\ \langle a_N, v \rangle \end{bmatrix}$$

$$x, y \in \mathbb{R}^N \Rightarrow \left\langle \sum_{i=1}^N x_i a_i, \sum_{j=1}^N y_j a_j \right\rangle = x^T A y$$

$$\left\langle \sum_{i=1}^N x_i a_i, v \right\rangle = b^T x$$

Y usando estas reformulaciones sobre (1) (mira final de la página anterior), se nos queda la siguiente expresión:

$$\exists x \in \mathbb{R}^N : y \in \mathbb{R}^N \Rightarrow \frac{1}{2} x^T A x - b^T x \leq \frac{1}{2} y^T A y - b^T y?$$

Volvemos a tener la función del principio del mínimo:

$$f(x) = \frac{1}{2} x^T A x - b^T x$$

Y podemos aplicar dicho principio ya que  $A$  es simétrica y definida positiva por la forma en la que la hemos definido (el producto escalar de un vector con él mismo siempre es  $\langle x, x \rangle > 0$  y  $= 0$  solo cuando  $x = 0$ ). Por lo tanto, la solución sabemos que será  $Ax = b$  (ecuaciones normales).

### Interpretación geométrica

$$Ax = b$$

$\Updownarrow$  (usamos que  $A = [\langle a_i, a_j \rangle]$   $b = \langle a_i, v \rangle$ )

$$\forall i \in \{1, \dots, N\} \quad \sum_{j=1}^N x_j \langle a_i, a_j \rangle = \langle a_i, v \rangle$$

$\Updownarrow$

$$\forall i \in \{1, \dots, N\} \Rightarrow \left\langle a_i, v - \sum_{j=1}^N x_j a_j \right\rangle = 0$$

$\Updownarrow$

$v - \sum_{j=1}^N x_j a_j$  es perpendicular a los vectores de la base  $S$ , por

lo que  $u = \sum_{j=1}^N x_j a_j$  es la proyección ortogonal de  $v$  sobre  $S$ .

Resumimos todo lo visto en el siguiente teorema:

## Teorema de la mejor aproximación

Sean  $(E, \langle \cdot, \cdot \rangle)$  un espacio euclídeo,  $S$  un subespacio vectorial finito dimensional con base  $\{a_1, \dots, a_N\}$  y sea  $v \in E$ . Existe un único vector  $u \in S$  (mejor aproximación de  $v$  en  $S$ , proyección ortogonal de  $v$  sobre  $S$ ) de forma que

$$\|u - v\| = \min \{ \|w - v\| : w \in S \}$$

Las coordenadas  $x \in \mathbb{R}^N$  de  $u$  en la base  $\{a_1, \dots, a_N\}$  caracterizadas por las ecuaciones normales  $Ax = b$

con  $A := [\langle a_i, a_j \rangle]$  y  $b := [\langle a_i, v \rangle]_{i=1}^N \in \mathbb{R}^N$  o bien

$$\text{por } \forall i \in \{1, \dots, N\} \Rightarrow \left\langle a_i, v - \sum_{j=1}^N x_j a_j \right\rangle = 0$$

## Aproximación uniforme

Teorema de Weierstrass:  $\mathbb{P}$  denso en  $C[a, b]$  (norma del máximo)

$$\Downarrow$$
$$\forall \varepsilon > 0, f \in C[a, b] \Rightarrow \exists p \in \mathbb{P} : \|f - p\|_\infty < \varepsilon$$

Polinomios de Bernstein:  $N \geq 1, f \in C([0, 1])$ , el polinomio de Bernstein  $B_N f$  de orden  $N$  para  $f$  está definido en cada  $x \in [0, 1]$  como

$$B_N f(x) := \sum_{i=0}^N f(i/N) \binom{N}{i} x^i (1-x)^{N-i}$$

Versión numérica del Teorema de Weierstrass

$$f \in C([0, 1]) \quad \lim_{N \rightarrow \infty} \|f - B_N f\| = 0$$

\* (Para el ejercicio 4 de la relación) En concreto, si  $f \in C^1([0, 1])$ ,  $\|f - B_N f\|_\infty \leq \frac{\|f'\|_\infty}{\sqrt{N}}$